

Dự đoán hành khách có khả năng sống sót trong vụ đắm tàu titanic bằng cách áp dụng mô hình máy học

Đinh Quang Minh, Dương Tấn Cường, Lê Thành Duy

Trường Đại học Sài Gòn, Việt Nam.

Liên hệ tác giả. E-mail(s): minh@gmail.com;

Tác giả đóng góp: cuong@gmail.com;

duy@gmail.com;

Các tác giả này đều có đóng góp như nhau trong công trình này.

Tóm tắt

Vụ đắm tàu Titanic là một trong những thảm họa hàng hải nổi tiếng nhất trong lịch sử, đồng thời cung cấp một bộ dữ liệu quý giá cho việc xây dựng và kiểm định các mô hình dự đoán. Nghiên cứu này nhằm dự đoán khả năng sống sót của hành khách trên tàu Titanic bằng cách áp dụng các thuật toán máy học khác nhau trên bộ dữ liệu công khai từ Kaggle. Quy trình nghiên cứu bao gồm tiền xử lý dữ liệu, tạo đặc trưng, huấn luyện và so sánh hiệu quả các mô hình như **Logistic Regression**, **Random Forest**, **Gradient Boosting** và **Support Vector Machine (SVM)**. Kết quả cho thấy mô hình Random Forest đạt độ chính xác cao nhất, khoảng 82%, cho thấy khả năng xử lý tốt các mối quan hệ phức tạp giữa các biến đặc trưng. Kết quả này khẳng định tiềm năng của máy học trong việc phân tích và dự đoán từ dữ liệu thực tế.

Từ khóa: Titanic; học máy; dự đoán sống sót; phân loại; Kaggle

1 Giới thiệu

Vụ đắm tàu Titanic vào năm 1912 là một trong những thảm họa hàng hải nghiêm trọng nhất trong lịch sử nhân loại, khiến hơn 1.500 người thiệt mạng trong tổng số hơn 2.200 hành khách và thủy thủ đoàn. Mặc dù sự kiện này đã diễn ra hơn một thế kỷ trước, song dữ liệu liên quan đến hành khách của tàu Titanic hiện nay vẫn được khai thác rộng rãi cho mục đích nghiên cứu trong lĩnh vực khoa học dữ liệu và học máy. Bộ dữ liệu Titanic, được công bố trên nền tảng **Kaggle**, bao gồm nhiều thông tin chi tiết về hành khách như giới tính, tuổi, hạng vé, số lượng người thân đi cùng, giá vé và điểm lên tàu. Đây là một nguồn dữ liệu điển hình để kiểm chứng khả năng của các mô hình dự đoán trong việc nhận diện các yếu tố ảnh hưởng đến khả năng sống sót của con người.

Trong bối cảnh đó, nghiên cứu này tập trung vào việc **ứng dụng các mô hình máy học (Machine Learning)** nhằm **dự đoán khả năng sống sót của hành khách trên tàu Titanic**. Thông qua việc áp dụng và so sánh các thuật toán khác nhau như **Logistic Regression**, **Random Forest**, **Gradient Boosting** và **Support Vector Machine (SVM)**, nghiên cứu hướng đến việc xác định mô hình có hiệu quả dự đoán cao nhất. Ngoài ra, quá trình tiền xử lý dữ liệu, phân tích đặc trưng (feature engineering) và đánh giá mô hình cũng được thực hiện nhằm đảm bảo tính khách quan và độ chính xác của kết quả.

Kết quả nghiên cứu không chỉ giúp hiểu rõ hơn về các yếu tố ảnh hưởng đến khả năng sống sót của hành khách, mà còn minh chứng cho **hiệu quả của các phương pháp học máy trong phân tích và ra quyết định dựa trên dữ liệu thực tế**. Đồng thời, đề tài cũng góp phần làm rõ quy trình ứng dụng học máy vào các bài toán phân loại (classification), mở ra hướng tiếp cận mới cho việc **ứng dụng trí tuệ nhân tạo trong lĩnh vực khoa học dữ liệu và an toàn con người**.

2. Dữ liệu và phương pháp nghiên cứu

2.1 Bộ dữ liệu Titanic

Bộ dữ liệu **Titanic – Machine Learning from Disaster**, được công bố trên nền tảng **Kaggle**, là một trong những bộ dữ liệu kinh điển và phổ biến nhất trong lĩnh vực khoa học dữ liệu. Bộ dữ liệu này được trích xuất từ danh sách hành khách của tàu Titanic trong chuyến hải trình định mệnh năm 1912, nhằm cung cấp thông tin để nghiên cứu, mô hình hóa và dự đoán khả năng sống sót của từng hành khách dựa trên các đặc điểm cá nhân và điều kiện đi lại.

Cụ thể, bộ dữ liệu bao gồm **891 mẫu (records)** trong tập huấn luyện (train.csv) và **418 mẫu** trong tập kiểm tra (test.csv), với **12 biến đặc trưng** mô tả thông tin chi tiết của từng hành khách.

Bộ dữ liệu này đặc biệt phù hợp cho các bài toán **phân loại nhị phân (binary classification)**, trong đó biến mục tiêu Survived là yếu tố cần dự đoán. Các thuộc tính như **giới tính, độ tuổi, hạng vé, giá vé, và nơi lên tàu** được xem là các yếu tố có ảnh hưởng mạnh đến khả năng sống sót của hành khách.

Trước khi đưa vào mô hình, dữ liệu được **tiền xử lý** bao gồm: xử lý giá trị thiếu (Age, Cabin, Embarked), mã hóa biến phân loại (Sex, Embarked, Title), và chuẩn hóa dữ liệu (Fare, Age). Quá trình này đảm bảo rằng dữ liệu đầu vào phù hợp với yêu cầu của các mô hình máy học.

2.2 Tổng quan bài toán

Vụ đắm tàu Titanic năm 1912 là một trong những thảm họa hàng hải nghiêm trọng nhất trong lịch sử, khiến hơn 1.500 người thiệt mạng. Dữ liệu hành khách trên tàu được thu thập và công bố rộng rãi, trở thành một bộ dữ liệu kinh điển trong lĩnh vực khoa học dữ liệu và học máy. Bài toán đặt ra là **dự đoán khả năng sống sót của hành khách dựa trên các đặc trưng cá nhân và điều kiện lên tàu**.

Về bản chất, đây là một **bài toán phân loại nhị phân (binary classification)**, trong đó biến mục tiêu là *Survived* (1: sống sót, 0: không sống sót). Các biến đầu vào bao gồm các yếu tố như **giới tính (Sex), tuổi (Age), hạng vé (Pclass), số anh chị em hoặc vợ chồng đi cùng (SibSp), số cha mẹ hoặc con đi cùng (Parch), giá vé (Fare) và bến lên tàu (Embarked)**.

Thách thức chính của bài toán là **xử lý dữ liệu thiếu, mã hóa các biến phân loại, chuẩn hóa dữ liệu, và lựa chọn mô hình dự đoán phù hợp**. Qua việc áp dụng các thuật toán học máy như **Logistic Regression, Random Forest, Gradient Boosting** hoặc **Support Vector Machine (SVM)**, nghiên cứu hướng tới mục tiêu không chỉ đạt độ chính xác cao mà còn **hiểu rõ các yếu tố ảnh hưởng đến khả năng sống sót** của hành khách.

2.3 Đề xuất mô hình

Bản chất của bài toán là **phân loại nhị phân (binary classification)**. Để đảm bảo kết quả có độ tin cậy cao, nghiên cứu đề xuất sử dụng và so sánh bốn thuật toán học máy phổ biến.

Logistic Regression: Mô hình tuyến tính nền tảng, đơn giản nhưng hiệu quả trong việc xác định mối quan hệ giữa các biến độc lập và biến mục tiêu. Dễ diễn giải, cho phép ước lượng trọng số của từng yếu tố.


Random Forest: Mô hình tổ hợp dựa trên nhiều cây quyết định, giúp giảm hiện tượng quá khớp (*overfitting*) và xử lý tốt dữ liệu phi tuyến tính. Ngoài ra, Random Forest cung cấp chỉ số *feature importance* giúp xác định tầm quan trọng của từng biến.

Support Vector Machine (SVM): Mô hình mạnh mẽ trong việc tìm siêu phẳng phân tách tối ưu giữa hai lớp dữ liệu. Phù hợp với các tập dữ liệu có biên ranh giới rõ ràng.

Gradient Boosting: Thuật toán tăng cường dần (boosting) hiệu quả bằng cách huấn luyện các mô hình cây yếu liên tiếp, trong đó mỗi mô hình mới sửa lỗi của mô hình trước. Phương pháp này thường đạt hiệu suất cao hơn Random Forest trong các bài toán phân loại có kích thước mẫu trung bình, và được xem là một trong những mô hình mạnh nhất cho dữ liệu dạng tabular.

2.4 Chi tiết triển khai

Do dữ liệu có nhiều chỗ bị thiếu sót nên ta phải tiền xử lí và tạo ra các đặc trưng mới trước khi áp dụng.



Hình 1: Phương pháp nguyên cứu tổng thể

Tiền xử lí dữ liệu (Pre-processing): làm sạch, xử lý missing, chuẩn hoá kiểu dữ liệu để đưa vào mô hình.

Tạo đặc trưng mới (Create new feature): Tạo các biến có ý nghĩa giúp mô hình nắm bắt thông tin ẩn.

Lựa chọn đặc trưng (Feature selection): giữ những biến có đóng góp, giảm nhiễu (noise) và quá khớp (overfitting).

Chuẩn bị dữ liệu cho mô hình (Feature input): mã hóa các dữ liệu dạng phân loại (categorical), 0/1 cho các loại dữ liệu nhị phân, dùng One-hot encoding cho các loại dữ liệu có nhiều giá trị.

Huấn luyện các mô hình (Train models): Huấn luyện và tinh chỉnh siêu tham số (hyperparameter tuning) cho các mô hình.

Đánh giá mô hình (Evaluate models): Dùng tập test (chưa thấy bởi model) và cross-val scores. Các chỉ số chính: Accuracy, Precision, Recall, F1-score, ROC-AUC, Confusion matrix.

Chọn mô hình tối ưu (Choose best model): Dựa vào metric chính (ví dụ F1 hoặc ROC-AUC) và độ ổn định (std across CV), chọn mô hình tốt nhất.

Kết quả (Results): mô hình tốt nhất.

3. Thí nghiệm và kết quả

3.1 Thiết lập thí nghiệm

Quy trình đào tạo:Chúng tôi chia tập dữ liệu thành hai phần, bao gồm dữ liệu thử nghiệm và dữ liệu huấn luyện, với tỷ lệ 70/30. Sau đó, chúng tôi áp dụng một số chiến lược, như đã đề cập trước đó.

3.2 Kết quả

Bảng 1: Kết quả các mô hình

Model	Accuracy	Precision	Recall	F1	Roc_auc
Logistic Regression	0.824	0.769	0.776	0.772	0.873
Random Forest	0.798	0.775	0.669	0.718	0.838
Gradient Boosting	0.794	0.779	0.650	0.708	0.842
SVM	0.828	0.787	0.757	0.772	0.865

Kết quả thực nghiệm cho thấy sự khác biệt đáng kể giữa các mô hình học máy được áp dụng trong bài toán dự đoán khả năng sống sót của hành khách tàu Titanic. Trong đó, **SVM (Support Vector Machine)** đạt **độ chính xác cao nhất, khoảng 83%**, đồng thời duy trì **điểm F1 ở mức cân bằng tốt** giữa Precision và Recall.

Mô hình **Logistic Regression** mặc dù có độ chính xác tổng thể thấp hơn một chút, nhưng lại thể hiện **khả năng dự đoán các hành khách sống sót tốt hơn**, thể hiện qua **Recall và ROC-AUC cao nhất** trong nhóm mô hình.

Ngược lại, **Random Forest** và **Gradient Boosting** tuy cho kết quả khá nhưng có xu hướng **overfitting**, làm giảm khả năng khái quát hóa khi áp dụng trên dữ liệu kiểm thử. Hai mô hình này cũng bỏ sót một số mẫu hành khách sống sót, khiến F1-score giảm so với SVM và Logistic Regression.

4. Kết luận

Từ các kết quả phân tích, có thể nhận định rằng **SVM** và **Logistic Regression** là hai mô hình hiệu quả và ổn định nhất trong bài toán dự đoán khả năng sống sót trên tàu Titanic. Trong đó, **SVM** được lựa chọn là **mô hình tối ưu**, nhờ đạt **độ chính xác (Accuracy)** và **F1-score cao nhất**, đồng thời duy trì **chỉ số ROC-AUC ổn định**.

Sự cân bằng tốt giữa khả năng nhận diện hành khách sống sót và giảm thiểu lỗi phân loại cho thấy **SVM là mô hình phù hợp nhất** cho bài toán này. Trong các nghiên cứu tương lai, việc mở rộng dữ liệu, tối ưu siêu tham số và kết hợp kỹ thuật học sâu có thể giúp nâng cao hơn nữa hiệu suất dự đoán.